

# **Лекция 1. Организация функционирования распределённых вычислительных систем**

**Перышкова Евгения Николаевна**

к.т.н. доцент Кафедры ВТ  
НГТУ

e-mail: e.peryshkova@gmail.com

# АКТУАЛЬНОСТЬ

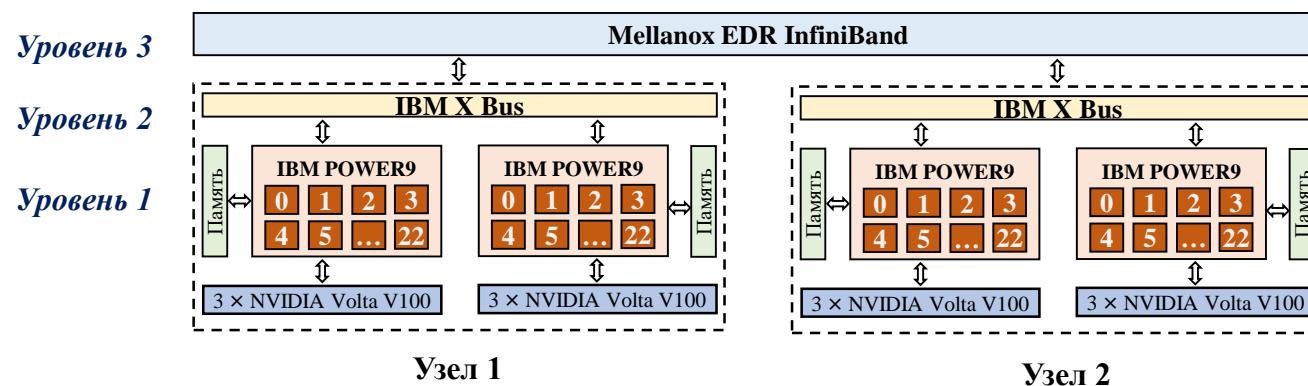
## ■ Вычислительная система (ВС) –

совокупность множества элементарных машин (ЭМ) и коммуникационной сети, связывающих их

## ■ Архитектурные свойства современных ВС [1]:

- мультиархитектура вычислительных узлов
- иерархическая организация коммуникационной среды
- большемасштабность

Две элементарные машины системы  
IBM BlueGene/Q Sequoia



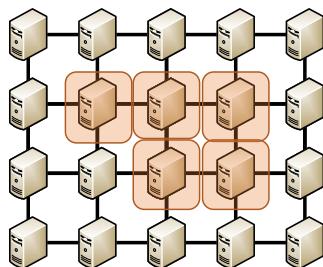
[1] Хорошевский В.Г. Распределенные вычислительные системы с программируемой структурой // Вестник СибГУТИ – 2010. – №2. – С. 3-41.

# РЕЖИМЫ ФУНКЦИОНИРОВАНИЯ ВС

## Мультипрограммные режимы функционирования ВС

### Режим обслуживания потока задач

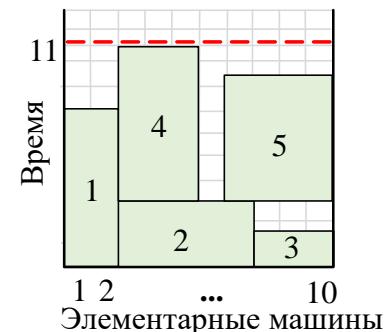
Формирование (суб)оптимальных подсистем элементарных машин для параллельных задач



Организация одновременного решения множества задач на ресурсах ВС

### Режим обработки набора задач

Построение расписаний решения параллельных задач (task scheduling)



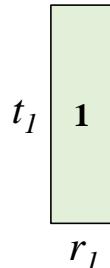
- Техника теории игр, стохастическое программирование (Хорошевский, 1973), (Юдин, 1974), (Ермольев, 1976)
- Алгоритмы на графах (Корнеев, Монахов, 1985), (Livingston, 2002)

- Точные методы: перебор, метод ветвей и границ
- Сведение к задаче упаковки объектов в контейнеры: 1DBPP, 2DSPP
- Алгоритмы локального поиска: генетические, имитация отжига, поиск с запретами, роевые алгоритмы

# РЕЖИМ ОБРАБОТКИ ЗАДАЧ С НЕФИКСИРОВАННЫМИ ПАРАМЕТРАМИ

## Задача с фиксированными параметрами (rigid)

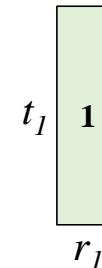
(1 вариант подсистемы ЭМ):



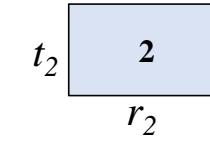
$$p_1 = (2, 10)$$

## Задача с нефиксированными параметрами (moldable)

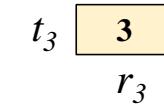
(3 варианта подсистем ЭМ):



$$p_1 = (2, 10)$$



$$p_2 = (5, 4)$$



$$p_3 = (3, 2)$$

**Преимущества поддержки в системах управления ресурсами параллельных задач с нефиксированными параметрами:**

- Сокращение суммарного времени решения задач
- Выполнение технико-экономических ограничений
  - Восстановление вычислительного процесса на допустимой подсистеме меньшего ранга
  - Лицензионные ограничения программ на размеры подсистемы

Актуальным является создание алгоритмов обработки наборов задач с нефиксированными параметрами

# **ПЛАНИРОВАНИЕ РЕШЕНИЯ ПАРАЛЛЕЛЬНЫХ ЗАДАЧ С НЕФИКСИРОВАННЫМИ ПАРАМЕТРАМИ**

# ОБРАБОТКА НАБОРА ЗАДАЧ С ФИКСИРОВАННЫМИ ПАРАМЕТРАМИ

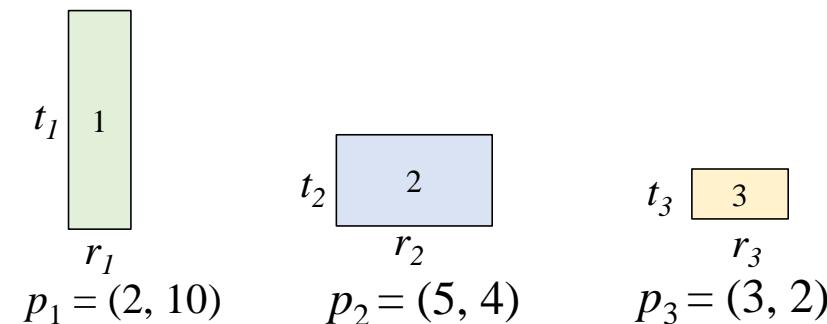
- **Задан** набор из  $m$  задач с *фиксированными* (rigid) рангами  $r_i$  и временем  $t_i$  решения
- **Требуется** построить расписание решения на ВС из  $n$  ЭМ задач набора – определить для каждой задачи подсистему ЭМ и момент запуска параллельных ветвей на ней
- Для обработки наборов задач с фиксированными параметрами разработаны эффективные методы и алгоритмы:
  - Сведение к задачи одномерной упаковки 1DBPP (В.Г. Хорошевский, 1967), (Поспелов, 1972)
  - Сведение к задаче двухмерной упаковки 2DSPP (Coffman, 1980)
  - Стохастические алгоритмы локального поиска (Мухачева, 2001)
  - Метод ветвей и границ (Сидельников, 2006)
  - Детерминированные алгоритмы с гарантированной оценкой точности (Ntene, 2009)
  - Алгоритмы решения задачи календарного планирования (Гимади, 2001), (Кочетов, 2000)

# ОБРАБОТКА НАБОРА ЗАДАЧ С НЕФИКСИРОВАННЫМИ ПАРАМЕТРАМИ

- **Задан** набор из  $m$  задач с *нефиксированными* (moldable) рангами  $r_i$  и временем  $t_i$  решения
- **Требуется** построить расписание решения на ВС из  $n$  ЭМ задач набора – определить для каждой задачи подсистему ЭМ и момент запуска параллельных ветвей на ней
- Задача с нефиксированными параметрами (moldable job) представлена вектором  $p_i$  из  $q_i$  различных вариантов параметров задачи:

$$p_i = (p_i^1, p_i^2, \dots, p_i^{q_i})$$

Задача с нефиксированными параметрами ( $q = 3$ )



[1] Sabin, G. *Moldable parallel job scheduling using job efficiency: an iterative approach*, 2007.

[2] Khandekar, R. *Real-time scheduling to minimize machine busy times*, 2010.

[3] Huang, K-C. *Online Scheduling of Moldable Jobs with Deadline*, 2015.

# ЗАДАЧА С НЕФИКСИРОВАННЫМИ ПАРАМЕТРАМИ

- Современные технико-экономические ограничения:
  - Некоторые параллельные задачи допускают реализацию только на подсистемах ЭМ с определенным свойствами, например, с числом процессорных ядер равным степени числа два
  - Лицензии значительной части коммерческих пакетов параллельного моделирования допускают их запуск только на фиксированных конфигурациях подсистем ЭМ
  - Отказы ресурсов в большемасштабных ВС и перспективных системах эксафлопсной производительности требуют поддержки возможности восстановления вычислительного процесса на допустимой подсистеме меньшего ранга
- Известные методы построения расписания решения задач не применимы для задач с нефиксированными параметрами, поэтому актуальным является создание новых алгоритмов формирования расписания решения задач с нефиксированными параметрами

# ОБРАБОТКА НАБОРА ЗАДАЧ С НЕФИКСИРОВАННЫМИ ПАРАМЕТРАМИ

- Требуется построить расписание  $S$  решения задач на ВС

$$S = ((s_1, x_1, k_1), (s_2, x_2, k_2), \dots, (s_m, x_m, k_m))$$

- $s_i$  – время начала решения  $i$ -ой задачи на ВС
- $x_i = (x_{i1}, x_{i2}, \dots, x_{ir_i^{k_i}})$  – подсистема ЭМ для выполнения ветвей программы,  $x_{ij}$  – номер ЭМ для выполнения ветви  $j$  задачи  $i$

$$T(S) = \max_{i \in J} \{s_i + t_i^{k_i}\} \rightarrow \min_{S \in \Omega}$$

при ограничениях:

$$\sum_{i \in J(t)} r_i^{k_i} \leq n, \quad \forall t \in \mathbb{R},$$

$$\prod_{i \in J(t)} \prod_{i' \in J(t) \setminus \{i\}} (x_{ij} - x_{i'j'}), \quad \forall t \in \mathbb{R}, \quad j = 1, 2, \dots, r_i^{k_i}, j' = 1, 2, \dots, r_{i'}^{k_{i'}},$$

$$\frac{1}{m} \sum_{i=1}^m \frac{w_i^{k_i}}{\max_{k=1, q_i} w_i^k} \geq w.$$

$$x_{ij} \in C, \quad i = 1, 2, \dots, m, \quad j = 1, 2, \dots, r_i^{k_i},$$

$$s_i \in \mathbb{R}, \quad k_i \in \{1, 2, \dots, q_i\}, \quad i = 1, 2, \dots, m.$$

# ПОСЛЕДОВАТЕЛЬНЫЙ ГЕНЕТИЧЕСКИЙ АЛГОРИТМ

## Генетический алгоритм формирования расписания решения задач с нефиксированными параметрами

- **Шаг 1.** Создание популяции из  $K$  допустимых расписаний.  
Расписание формируется с помощью эвристических алгоритмов FFDH или BFDH

- **Шаг 2.** Получение новых особей путем «скрещивания» пары расписаний – два расписания делятся на  $G$  частей и переставляются. Если особь не скрещивается, к ней применяется оператор мутации

- **Шаг 3.** Упорядочивание всей популяции по значению целевой функции  $T(S)$ . В популяции остаются лучшие  $K$  особей (расписаний)

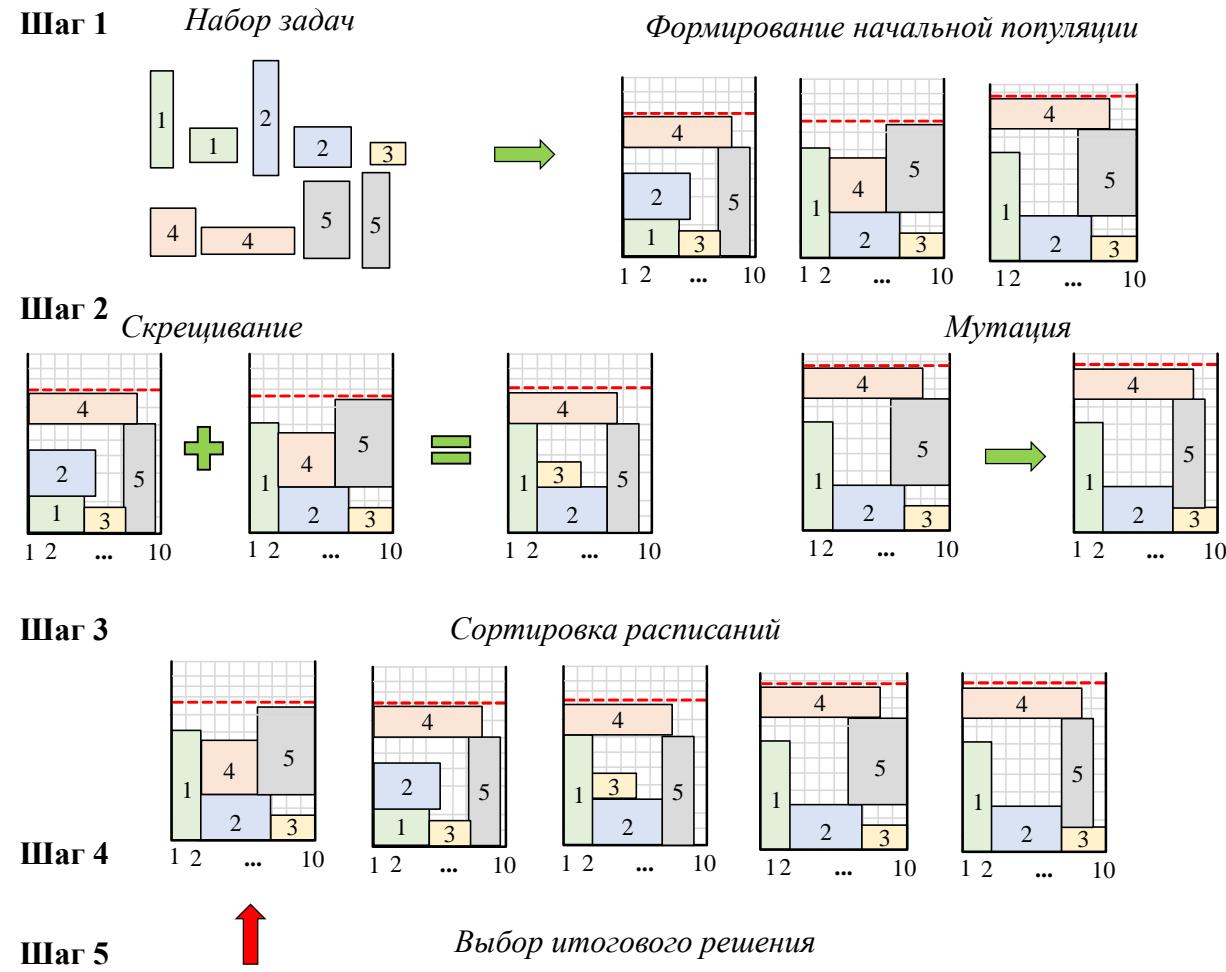
- **Шаг 4.** Если количество эволюционных циклов не достигло предельного значения  $V$ , то возврат к шагу 2

- **Шаг 5.** За итоговое решение принимается особь с экстремальным значением целевой функции  $T(S)$  в текущей популяции

Вычислительная сложность алгоритма равна:

$$T = O(K \cdot m + K \cdot T_{2DSPP} + V \cdot K \log K + V \cdot K),$$

где  $T_{2DSPP}$  – время работы алгоритмов упаковки,  
 $K$  – размер популяции,  
 $V$  – количество эволюционных циклов.



# ИССЛЕДОВАНИЕ ГЕНЕТИЧЕСКОГО АЛГОРИТМА

- Алгоритм реализован на C++ в пакете MOJOS
- Проведено моделирование алгоритма на тестовых наборах задач для моделей ВС с числом ЭМ  $n = 1024, 4096, 16384, 65536$  и количеством задач в наборе  $m = 1000, 2000$  и  $3000$
- Показатели эффективности алгоритма:

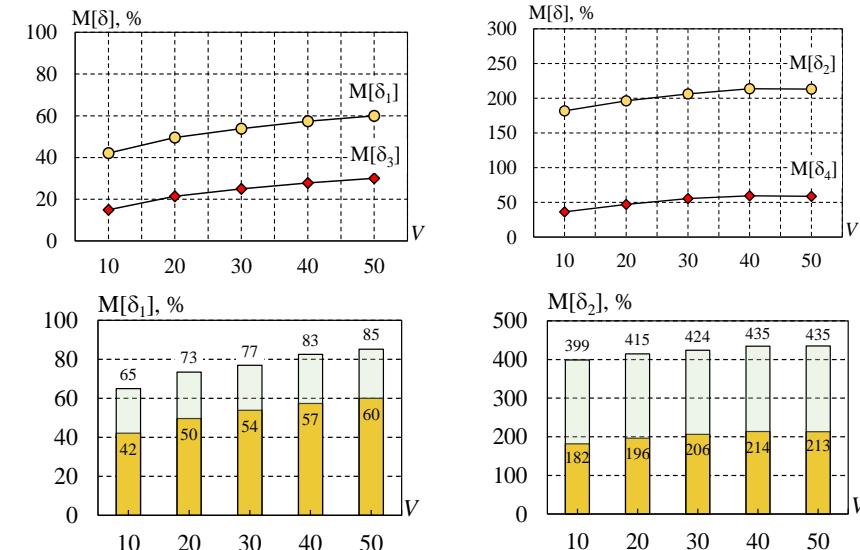
$$\delta_1 = (T_{BFDH} - T)/T, \quad \delta_2 = (T_{FFDH} - T)/T,$$

$$\delta_3 = (T_{BFDH\_INIT} - T)/T, \quad \delta_4 = (T_{FFDH\_INIT} - T)/T$$

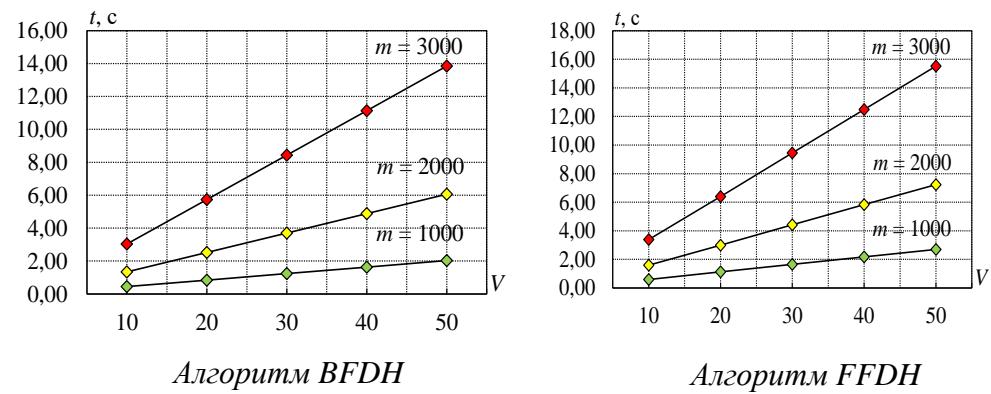
- $T_{BFDH\_INIT}$  – значение целевой функции от начального решения, полученного алгоритмом BFDH
- $T_{FFDH\_INIT}$  – значение целевой функции от начального решения, полученного алгоритмом FFDH
- $T$  – значение целевой функции от решения, полученного генетическим алгоритмом
- $T_{BFDH}$  и  $T_{FFDH}$  – значение целевой функции от решений, полученных алгоритмами BFDH и FFDH

Генетический алгоритм построения расписаний решения задач с нефиксированными параметрами обеспечивает **сокращение суммарного времени выполнения задач в среднем на 45%** относительно начальных решений, получаемых известными алгоритмами FFDH и BFDH

Зависимость математического ожидания и среднеквадратического отклонения от количества эволюционных циклов  $V$   
( $n = 1024, m = 1000; K = 16, w = 75\%, P = 90\%, G = 2$ )



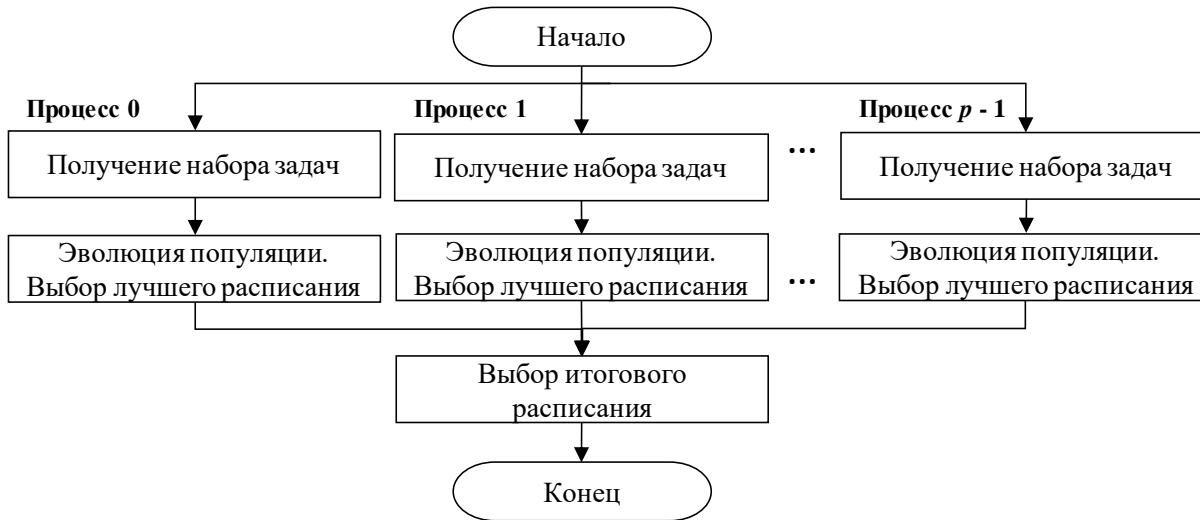
Зависимость времени работы алгоритма от количества эволюционных циклов  $V$  и числа  $m$  задач в наборе (1024 ЭМ)



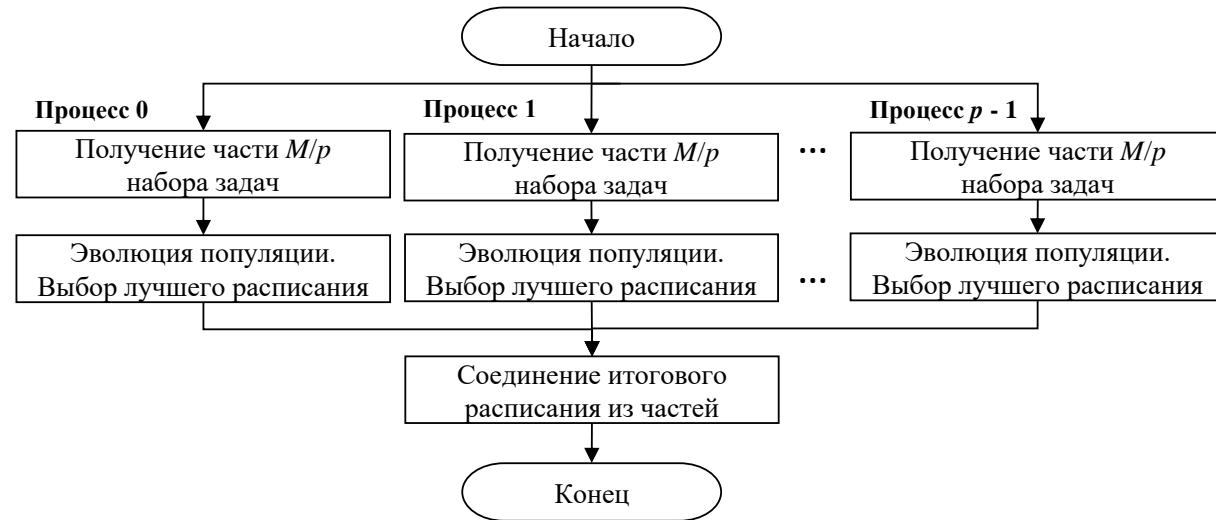
# ПАРАЛЛЕЛЬНЫЕ ГЕНЕТИЧЕСКИЕ АЛГОРИТМЫ

## Параллельные генетические алгоритмы формирования расписания решения задач с нефиксированными параметрами

Алгоритм на основе метода мультистарта



Алгоритм на основе декомпозиции набора задач



$M$  – количество задач в наборе,  $p$  – количество процессов программы

- Алгоритмы реализованы на языке С в модели передачи сообщений MPI
- Характеризуются линейной зависимостью ускорения от числа процессов

[\*] В.Г. Хорошевский, М.Г. Курносов, С.Н. Мамойленко, К.В. Павский, А.В. Ефимов, А.А. Пазников, Е.Н. Перышкова. Масштабируемый инструментарий параллельного мультипрограммирования пространственно-распределенных вычислительных систем // Вестник СибГУТИ. – 2011. – № 4. – С. 3-18.

# ИНТЕРГАЦИЯ В СИСТЕМУ УПРАВЛЕНИЯ РЕСУРСАМИ TORQUE И ПЛАНИРОВЩИК MAUI

- Выполнена интеграция пакета MOJOS с системой TORQUE и планировщиком Maui
- Язык запросов расширен новой структурой для описания вектора допустимых подсистем ЭМ  

```
-L nodes = value @ ppn = value @
weight = value @ walltime = value,
```
- Эксперименты на вычислительном кластере: 18 узлов, сеть Gigabit Ethernet; наборы задач:  $m = 100, 200, 400$  и  $800$
- Показатели эффективности:  
 $\delta_1 = (T_T - T)/T$ ,  $\delta_2 = (T_M - T)/T$ ,  
 $\delta_3 = (T_{TQ} - T_Q)/T_Q$ ,  $\delta_4 = (T_{MQ} - T_Q)/T_Q$
- $T_T$  и  $T_{TQ}$  – время решения задач и время ожидания задач в очереди, обеспечиваемое системой TORQUE
- $T_M$  и  $T_{MQ}$  – время решения задач и время ожидания задач в очереди, обеспечиваемое планировщиком Maui
- $T$  и  $T_Q$  – время решения задач и время ожидания задач в очереди, обеспечиваемое разработанными автором средствами

| Количество задач в наборе | $T_T$ , с | $T_M$ , с | $T$ , с | $M[\delta_1]$ , % | $M[\delta_2]$ , % |
|---------------------------|-----------|-----------|---------|-------------------|-------------------|
| 100                       | 13403     | 12317     | 11188   | 19,80             | 10,09             |
| 200                       | 50426     | 45171     | 43195   | 16,74             | 4,57              |
| 400                       | 207528    | 202364    | 175033  | 18,57             | 15,61             |
| 800                       | 836394    | 796453    | 713580  | 17,21             | 11,61             |

| Количество задач в наборе | $T_{TQ}$ , с | $T_{MQ}$ , с | $T$ , с | $M[\delta_3]$ , % | $M[\delta_4]$ , % |
|---------------------------|--------------|--------------|---------|-------------------|-------------------|
| 100                       | 323          | 310          | 246     | 31,30             | 26,02             |
| 200                       | 372          | 356          | 326     | 14,11             | 9,20              |
| 400                       | 684          | 697          | 605     | 13,06             | 15,21             |
| 800                       | 1324         | 1294         | 1200    | 10,33             | 7,83              |

В среднем применение разработанных средств для системы TORQUE на рассмотренных наборах **позволяет сократить суммарное время решения задач на 24 % и на 21 %** для планировщика Maui

# **АЛГОРИТМЫ ФОРМИРОВАНИЯ ПОДСИСТЕМ ЭЛЕМЕНТАРНЫХ МАШИН**

# АЛГОРИТМЫ ФОРМИРОВАНИЯ ПОДСИСТЕМ ЭЛЕМЕНТАРНЫХ МАШИН

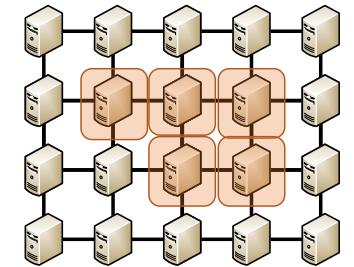
Заданы распределенная ВС и количество  $M$  ветвей в параллельной программе.

Требуется сформировать подсистему, обеспечивающую эффективную реализацию коллективных схем межмашинных обменов.

Обозначения:

- $l_{pq}$  – кратчайшее расстояние между ЭМ  $p$  и  $q$  в структуре ВС.
- $b_{pq}$  – пропускная способность канала связи между ЭМ  $p$  и  $q$ .

Распределенная ВС  
 $N = 20, M = 5$



## ВС с однородной структурой сети

$$L(X) = \left( \prod_{p=1}^{n-1} \prod_{q=p+1}^n (x_p x_q (l_{pq} - 1) + 1) \right) \rightarrow \min_{(x_p)}$$

при ограничениях:

$$\sum_{p=1}^n x_p = M,$$

$$x_p \in \{0, 1\}, \quad p = 1, 2, \dots, n.$$

## ВС с иерархической организацией

$$B(X) = \left( \prod_{p=1}^{n-1} \prod_{q=p+1}^n (x_p x_q (b_{pq} - 1) + 1) \right) \rightarrow \max_{(x_p)}$$

при ограничениях:

$$\sum_{p=1}^n x_p = M,$$

$$x_p \in \{0, 1\}, \quad p = 1, 2, \dots, n.$$

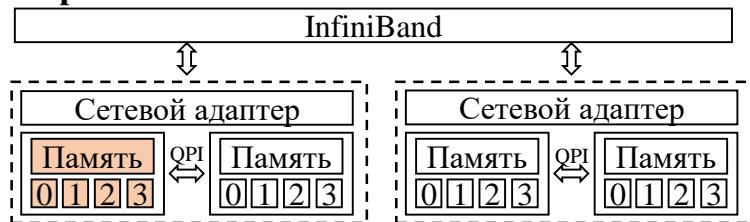
# АЛГОРИТМЫ ФОРМИРОВАНИЯ ПОДСИСТЕМ ЭЛЕМЕНТАРНЫХ МАШИН

- Задан ранг  $R$  подсистемы ЭМ (количество необходимых процессорных ядер), конфигурация ВС на базе многопроцессорных узлов с общей памятью
- Требуется из  $K$  допустимых вариантов подсистем ранга  $R$  выбрать подсистему ЭМ, обеспечивающую минимум времени выполнения информационных обменов

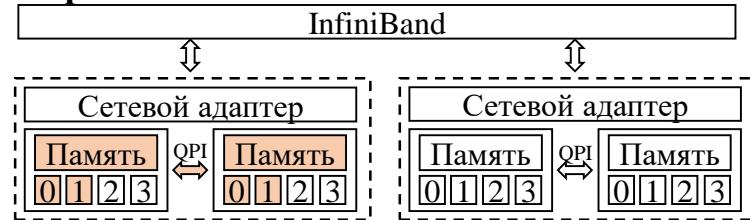
Алгоритм формирования подсистем ЭМ, минимизирующий время реализации коллективных обменов типа «all-to-all» и учитывающий загруженность каналов связи, возникающую в следствии их конкурентного использования процессами параллельных программ

## Формирование подсистемы ЭМ ранга 4

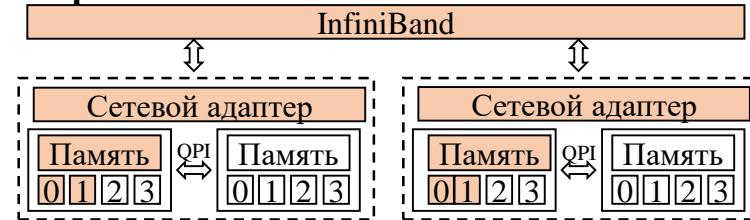
### Вариант 1



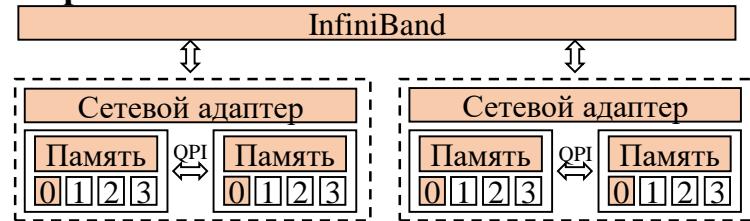
### Вариант 2



### Вариант 3

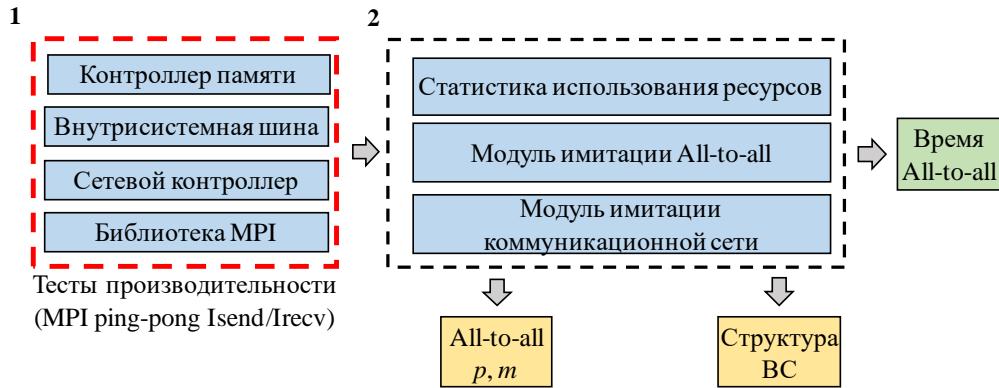


### Вариант 4



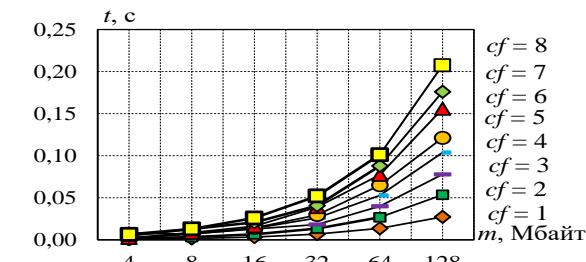
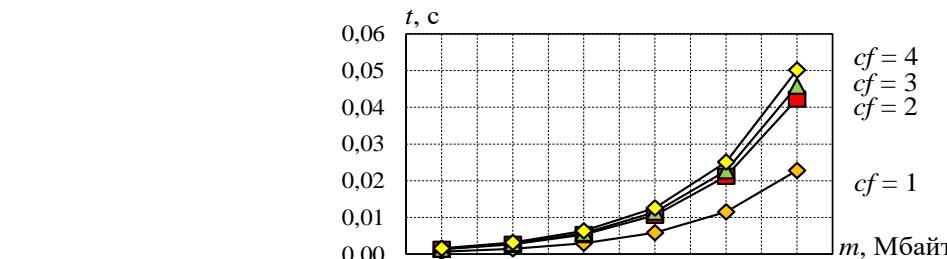
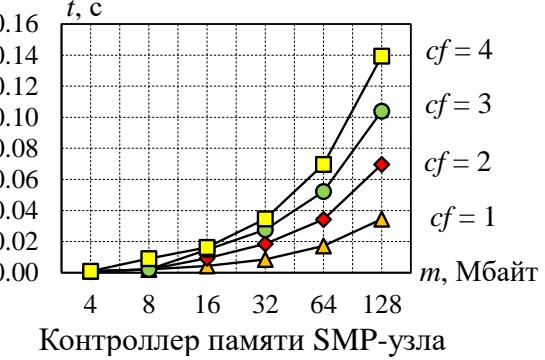
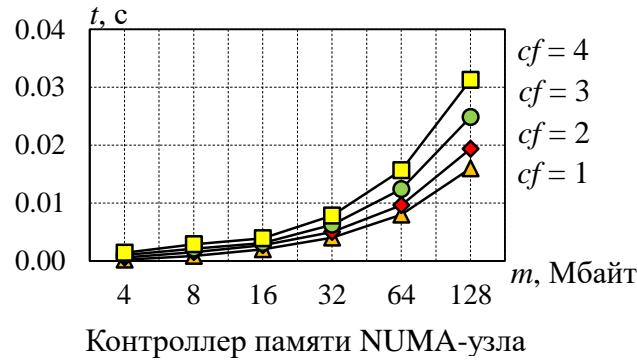
# АНАЛИЗ КОНКУРЕНТНОГО ИСПОЛЬЗОВАНИЯ КАНАЛОВ СВЯЗИ

Метод формирования подсистем ЭМ: 1 этап

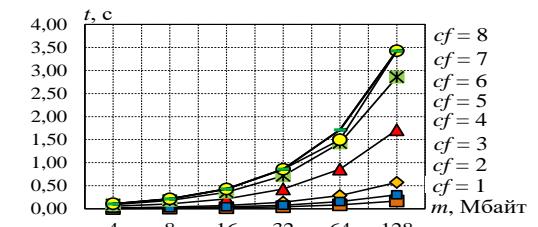


| $m$ , Мбайт | Коэффициент падения производительности $t(m, cf) / t(m, 1)$ |          |          |          |
|-------------|---|----------|----------|----------|
|             | $cf = 1$  | $cf = 2$ | $cf = 3$ | $cf = 4$ |
| 128         | 1   | 2,03     | 3,03     | 4,06     |
| 64          | 1   | 2,00     | 3,04     | 4,06     |
| 32          | 1   | 2,17     | 3,23     | 4,03     |
| 16          | 1   | 2,17     | 3,43     | 3,80     |
| 8           | 1   | 1,01     | 1,01     | 4,27     |
| 4           | 1   | 0,86     | 0,82     | 0,96     |

Время  $t$  передачи сообщения размером  $m$  байт при одновременном разделении канала связи  $cf$  процессами



Сетевой контроллер InfiniBand

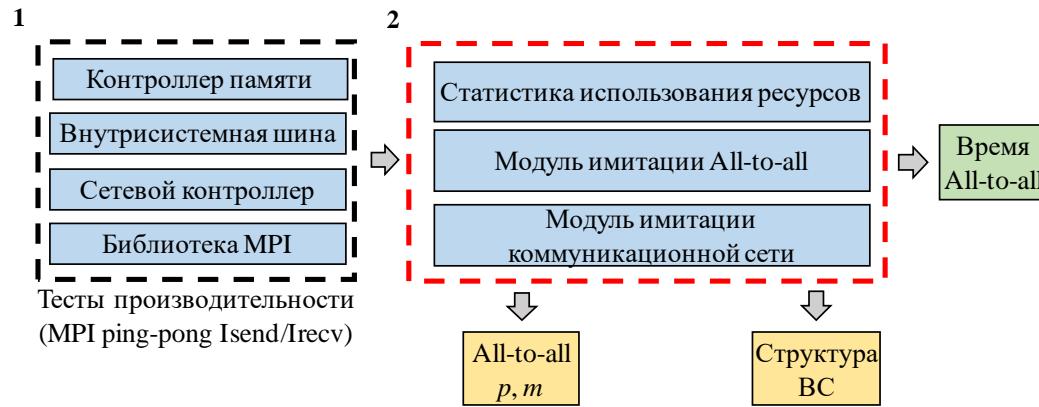


Сетевой контроллер Gigabit Ethernet

[\*] E. Peryshkova, M. Kurnosov Experimental Study of Network Contention Effects on All-to-All Operation // Proc. of the 14th International Scientific-Technical Conference «Actual Problems of Electronic Instrument Engineering» (APEIE-2018), 2018. – Vol. 1, Part 4. – P. 506-510. (Scopus)

# АНАЛИЗ КОНКУРЕНТНОГО ИСПОЛЬЗОВАНИЯ КАНАЛОВ СВЯЗИ

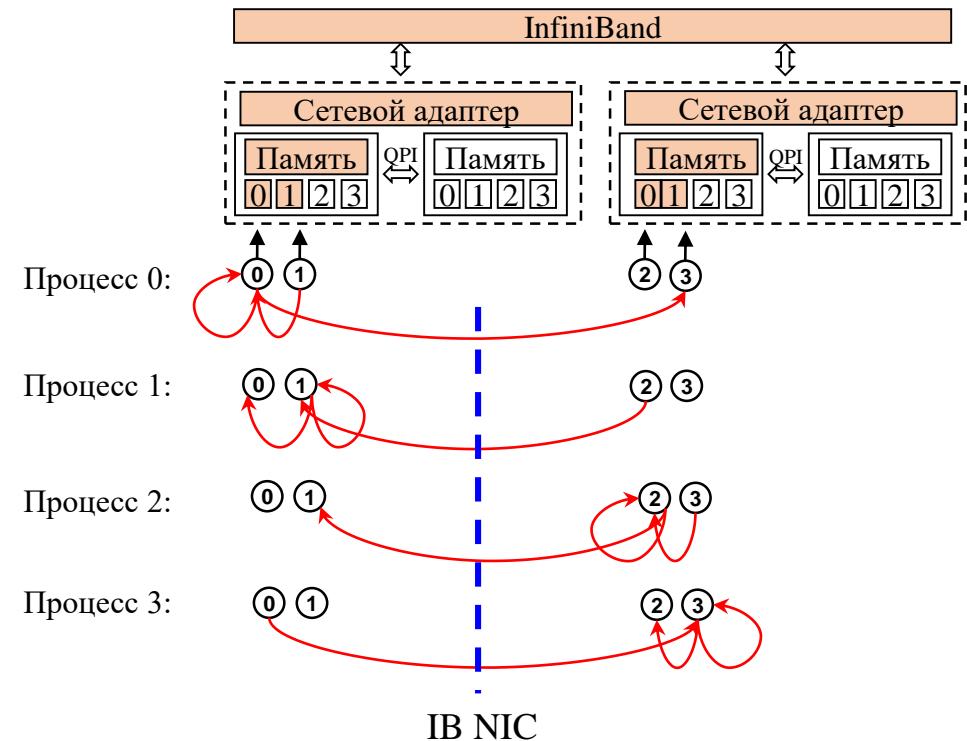
Метод формирования подсистем ЭМ: 2 этап



## Шаг 1, размер блока 2:

- **Процесс 0:** отправляет и принимает сообщение процессу 0, принимает от процесса 1 и отправляет 3
- **Процесс 1:** отправляет и принимает сообщение процессу 1, принимает от процесса 2 и отправляет 0
- **Процесс 2:** отправляет и принимает сообщение процессу 2, принимает от процесса 3 и отправляет 1
- **Процесс 3:** отправляет и принимает сообщение процессу 3, принимает сообщение от 0 и отправляет 2

## Шаг блочного алгоритма операции MPI\_Alltoall



Сетевой адаптер первого узла разделяют 4 процесса

$$t(m, 4)$$

# ЭВРИСТИЧЕСКИЙ АЛГОРИТМ ФОРМИРОВАНИЯ ПОДСИСТЕМ ЭМ

---

**Входные данные:**  $S$  – множество симметричных подсистем

**Выходные данные:**  $S$  – упорядоченное по возрастанию оценочного времени выполнения операции «all-to-all» множество симметричных подсистем

---

```
function ALLOCATESUBSYS (S)
    for each subsystem[i] in S do
        time[i] = ESTIMATEONSUBSYSTEM(i)
    end for
    SORT(S, COMPARETIME)
    return S
end function
```

---

**Входные данные:**  $subsystem$  – симметричная подсистема ЭМ,  $m$  – размер передаваемого сообщения

**Выходные данные:**  $totaltime$  – прогнозируемое время выполнения операции All-to-All

---

```
function ESTIMATEONSUBSYSTEM (subsystem, m)
    totaltime = 0
    for all steps of All-to-All do
        time = 0
        l = ESTIMATELAYER(step)
        cf = ESTIMATECONTENTIONFACTOR(step, l)
        time = t(l, m, cf)
        totaltime = totaltime + time
    end for
    return argmax {totaltime}
end function
```

---

# ИССЛЕДОВАНИЕ АЛГОРИТМА ФОРМИРОВАНИЯ ПОДСИСТЕМ ЭМ

- Алгоритм реализован на языке C++
- Конфигурация ВС: 6 NUMA-узлов (2 x Intel Quad Xeon E5620, RAM 24 GiB), InfiniBand QDR
- Программное обеспечение: GNU/Linux x86-64, MVAPICH 2.3

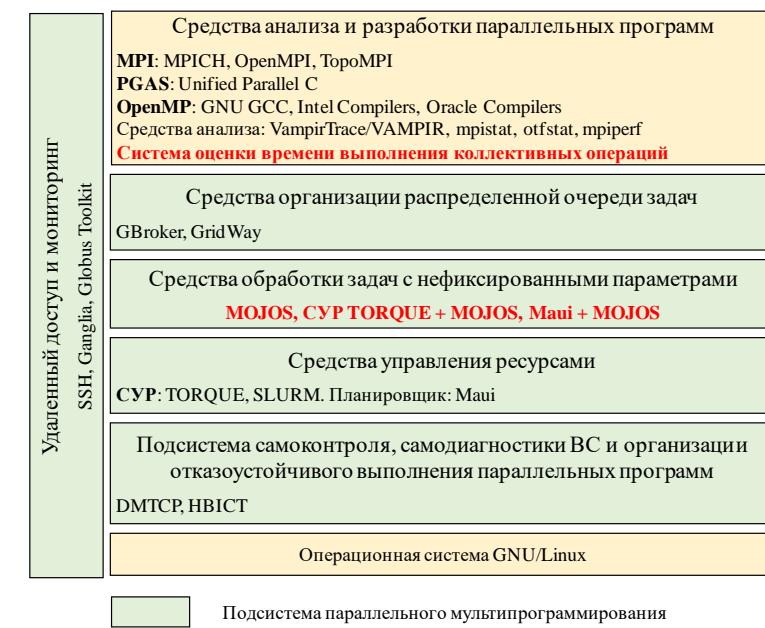
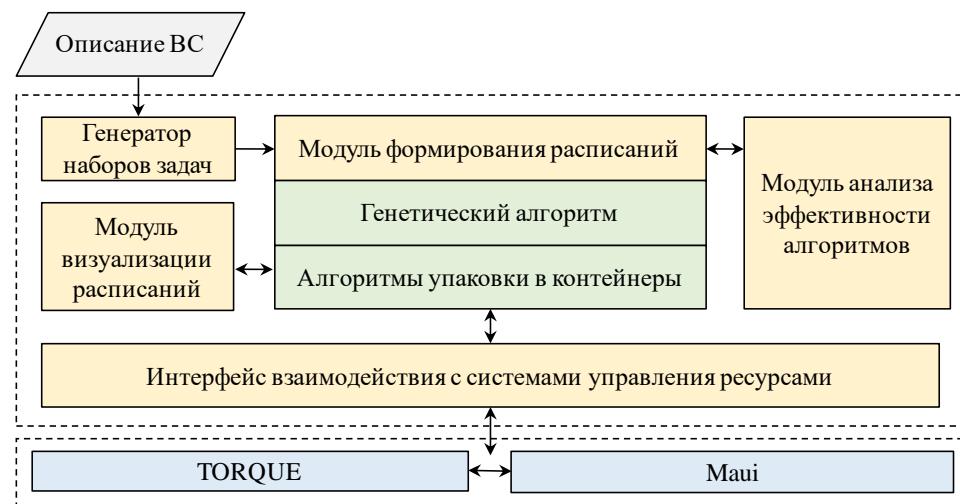
| Требуемое количество процессов | Время выполнения операции All-to-all, с |                    |                    |
|--------------------------------|---|--------------------|--------------------|
|                                | 1 ВУ, 2 процессора                      | 2 ВУ, 1 процессор  |                    |
| 2                              | 0,00016                                 | 0,00033            |                    |
| Система моделирования          |   |                    |                    |
| Реальный запуск                | 0,00044                                 | 0,00061            |                    |
| Установленный порядок          | 1                                       | 2                  |                    |
| 4                              | 1 ВУ, 4 процессора                      | 2 ВУ, 2 процессора | 4 ВУ, 1 процессор  |
| Система моделирования          | 0,0019                                  | 0,0021             | 0,0018             |
| Реальный запуск                | 0,0031                                  | 0,0036             | 0,0029             |
| Установленный порядок          | 2                                       | 3                  | 1                  |
| 8                              | 1 ВУ, 8 процессоров                     | 2 ВУ, 4 процессора | 4 ВУ, 2 процессора |
| Система моделирования          | 0,00384                                 | 0,19               | 0,0058             |
| Реальный запуск                | 0,00754                                 | 0,09               | 0,0076             |
| Установленный порядок          | 1                                       | 3                  | 2                  |

На вычислительных кластерах с многопроцессорными NUMA-узлами и сетью связи стандарта InfiniBand алгоритм **обеспечивает сокращение времени информационных обменов от 16% до 31%** по сравнению с известным алгоритмом формирования подсистем FF (first fit)

# **МУЛЬТИКЛАСТЕРНАЯ ВЫЧИСЛИТЕЛЬНАЯ СИСТЕМА**

# ИНСТРУМЕНТАРИЙ ПАРАЛЛЕЛЬНОГО МУЛЬТИПРОГРАММИРОВАНИЯ

- На основе созданных алгоритмов разработаны программные пакеты MOJOS обслуживания потоков параллельных задач с нефиксированными параметрами, программное расширение системы управления ресурсами TORQUE, программный пакет поддержки режима обслуживания потока задач с нефиксированными параметрами для планировщика Maui (в соавторстве), программные средства оценки времени реализации коммуникационных операций типа «all-to-all» (в соавторстве)
- Предложенные пакеты вошли в состав инструментария параллельного мультипрограммирования пространственно-распределенной мультиклusterной ВС, созданной членами ведущей научной школы РФ (НШ-9505.2006.9, НШ-2121.2008.9, НШ-5176.2010.9, НШ-2175.2012.9, основатель – чл.-корр. РАН В.Г. Хорошевский)



[\*] А.В. Ефимов, С.Н. Мамойленко, Е.Н. Перышкова Модернизация системы управления ресурсами PBS/TORQUE и планировщика Maui для обслуживания масштабируемых задач // Вестник компьютерных и информационных технологий. – 2016. – № 2. – С. 34-39.

**Спасибо за внимание!**

**Перышкова Евгения Николаевна**

к.т.н. доцент Кафедры ВТ

НГТУ

e-mail: e.peryshkova@gmail.com